

Predição do desmatamento no Cerrado utilizando aprendizado de máquina

Gabriel Prisco Diogo de Holanda^{1*}; Paulo Guilherme Alarcon Fernandes²

¹ Engenheiro Civil. Rua Fonseca Lobo 1185 – Aldeota; 60175-020 Fortaleza, Ceará, Brasil.

² Mestre em Economia Regional pela Universidade Estadual de Londrina (UEL). Rodovia Celso Garcia Cid, PR-445, Km 380 - Campus Universitário; 86057-970 Londrina, Paraná, Brasil

*e-mail: gabrielprisco3@gmail.com

Predição do desmatamento no Cerrado utilizando Aprendizado de Máquina

Resumo

O desmatamento no Cerrado é um problema ambiental crítico, com impactos significativos sobre a biodiversidade e o clima. Diante disso, este trabalho teve como objetivo analisar a adequabilidade de diferentes ferramentas de “Machine Learning” para a previsão do desmatamento no bioma, utilizando dados históricos de 2000 a 2023. Foram comparados três modelos: uma “random forest”, uma rede neural “feedforward” e uma rede neural recorrente. A metodologia envolveu a preparação dos dados, a construção e treinamento dos modelos, seguida de uma avaliação utilizando métricas estatísticas. A análise indicou que dentre as três técnicas exploradas a “random forest” foi a que obteve o melhor desempenho. A conclusão do estudo reforça a complexidade do problema tratado, sendo imprescindível a escolha apropriada de técnicas de pré-processamento e de modelos que ofereçam uma abordagem mais robusta para lidar com fenômenos de alta variabilidade e valores extremos.

Palavras-chave: previsão; machine; learning; desflorestamento; bioma.

Introdução

O Cerrado, um dos biomas mais ricos em biodiversidade do mundo, enfrenta desafios significativos relacionados ao desmatamento, degradação ambiental e perda de habitats naturais. Este bioma, que abrange uma vasta extensão territorial no Brasil, tem sido alvo de intensa atividade humana, resultando em sérios impactos ambientais. Ao lado da Mata Atlântica, é considerado um dos “hotspots” mundiais, ou seja, um dos biomas mais ricos e ameaçados do mundo (ICMBIO, acessado em 04/04/2024). Segundo Dias (1992), na região de cerrado, devido a sua grande heterogeneidade, podem ocorrer até 5% da fauna mundial, e cerca de um terço da fauna brasileira. O desmatamento no Cerrado representa uma ameaça iminente à sua biodiversidade única, bem como aos serviços ecossistêmicos vitais que ele fornece, como a regulação do clima, conservação do solo e manutenção dos recursos hídricos.

Nos últimos anos, houve um aumento alarmante nas taxas de desmatamento no Cerrado, sendo as principais causas do desmatamento do Cerrado as monoculturas e pastagens, enquanto os reservatórios hidrelétricos e a expansão das áreas urbanas são causas secundárias (MMA, 2016). Um estudo concluiu que 55% do Cerrado já foram desmatados ou transformados pela ação humana (Machado et al., 2004), o que equivale a uma área de 880.000km², ou seja, quase três vezes a área desmatada na Amazônia brasileira (Klink & Machado, 2005). Ainda segundo Klink & Machado (2005), as

transformações ocorridas no Cerrado trouxeram grandes danos ambientais – fragmentação de habitats, extinção da biodiversidade, invasão de espécies exóticas, erosão dos solos, poluição de aquíferos, degradação de ecossistemas, alterações nos regimes de queimadas, desequilíbrios no ciclo do carbono e possivelmente modificações climáticas regionais. Esse cenário tem despertado preocupações crescentes entre a comunidade científica, os tomadores de decisão e a sociedade em geral, destacando a necessidade urgente de desenvolver abordagens eficazes para monitorar e prever o desmatamento nesta região.

Neste contexto, o uso de técnicas avançadas de aprendizado de máquina, como redes neurais e florestas aleatórias, tem se mostrado promissor para prever padrões de dados históricos. A capacidade de algoritmos de “Machine Learning” [ML] de modelar relações temporais e capturar padrões complexos nos dados espaciais e temporais os torna uma ferramenta valiosa para análise e previsão de mudanças no uso da terra.

Diante disso, este trabalho propõe investigar a aplicação de técnicas de aprendizado de máquina na predição do desmatamento no Cerrado. Por meio da análise de dados históricos de desmatamento, pretende-se desenvolver um modelo preditivo capaz de identificar padrões nas taxas de desmatamento. A realização deste estudo é justificada pela sua relevância para a conservação do Cerrado, bem como para o desenvolvimento de estratégias eficazes de mitigação do desmatamento e promoção do uso sustentável da terra.

Em suma, este trabalho visou contribuir para o avanço do conhecimento científico sobre o desmatamento no Cerrado, pretendendo fornecer uma abordagem eficaz para prever e monitorar as mudanças no uso da terra. Espera-se que os resultados obtidos possam subsidiar ações de conservação e manejo sustentável deste importante bioma, contribuindo para sua preservação a longo prazo e para o bem-estar das comunidades que dependem dele.

Dessa forma, o objetivo central deste trabalho foi realizar a análise da situação do desmatamento no Cerrado sob diferentes ferramentas de ML e comparar a eficácia dos diferentes modelos frente a esse tipo de problema. Ao final do trabalho, espera-se obter conclusões acerca da adequabilidade dos modelos à predição do fenômeno em questão por meio de dados históricos.

Material e Métodos

Os dados para realização do trabalho foram obtidos pelo portal TerraBrasilis vinculado ao INPE. Trabalhou-se com dados em formatos espaciais (SHP,DBF,TIF...), referentes ao período de 2000 a 2023, no QGIS para manipulação e transformações para formatos compatíveis com os algoritmos de ML. Os modelos mencionados para realizar o objetivo principal do trabalho foram uma Rede Neural "Feedforward" [FNN], uma Rede

Neural Recorrente [RNN] e uma "Random Forest" [RF], construídas utilizando pacotes de ML do "software" R, como "rnn", "caret" e "neuralnet", as quais foram otimizadas para o melhor resultado possível no conjunto de teste, alterando-se parâmetros como arquitetura, número de épocas, neurônios da camada escondida, taxa de aprendizado, variáveis de entrada, dentre outros. Ademais, a região abordada pelos dados é a região ocupada pelo Cerrado no Brasil, a qual pode ser ilustrada pelo seguinte mapa (Figura 1):



Figura 1. Mapa da região do Cerrado no Brasil

Fonte: <https://brasilecola.uol.com.br/brasil/cerrado.htm> acesso em: 15 out. 2024

Posteriormente foi caracterizado o conjunto de dados do trabalho, detalhada a etapa de pré-processamento de dados e explicado o funcionamento dos algoritmos a serem utilizados. Além disso, foram comparados entre si os modelos por métricas estatísticas, como o Coeficiente De Determinação [R^2], o Erro Absoluto Médio [MAE], o Erro Percentual Médio Absoluto [MAPE] e a Raiz Do Erro Quadrático Médio [RMSE].

Conjunto dos Dados

O conjunto de dados obtidos do portal TerraBrasilis será o referente ao arquivo com dados vetoriais do Projeto de Monitoramento do Desmatamento na Amazônia Legal por Satélite [PRODES] do bioma cerrado de 2000 a 2023, graficamente pode ser representado por um conjunto de polígonos. Assim, é ilustrado na Tabela 1 o conjunto de dados e suas variáveis:

Tabela 1. Conjunto de dados da pesquisa

Variável (Coluna)	Tipo de dados	Informações
"fid"	"numeric"	representa "ids" dos polígonos.
"state"	"chr"	representa os 13 estados brasileiros presentes
"path_row"	"chr"	código da cena formado por linha/coluna da grade de passagem do satélite.
"main_class"	"chr"	nome da classe principal atribuída à feição, iremos utilizar apenas as observações com valor "DESMATAMENTO"
"class_name"	"chr"	possui a inicial "'d" de desmatamento e o ano referente ao dado, exemplos: "d2021" e "d2007"
"def_cloud"	NA	ano que indica desde quando esta área está coberta por nuvens (todos os valores são NA).
"julian_day"	"numeric"	equivale ao dia no ano.
"image_date"	tipo "date"	data com formato "aaaa-mm-dd"
"year"	"numeric"	equivale ao ano
"area_km"	"numeric"	equivale a área de desmatamento do polígono em km ² .
"scene_id"	"numeric"	equivale a um "id" da cena do satélite.
"source"	"chr"	vale "cerrado" em todo o conjunto de dados
"satellite"	"chr"	é o nome do satélite que foi utilizado para a obtenção do dado
"sensor"	"chr"	é uma sigla que representa o sensor utilizado.
"uuid"	"chr"	é um código de identificação
"geometry"	"sfc_POINT"	são os atributos geométricos do polígono, ou seja, as coordenadas dos pontos que o formam.

Fonte: Dados originais da pesquisa

Pré-processamento de dados

No software QGIS, adicionou-se uma camada com centróides relativos a cada polígono, assim se obteve, para cada polígono e suas características, um ponto no espaço para representá-las, o que auxiliou a organização dos dados.

Em seguida, foram carregados os arquivos ".shp", contendo os dados geoespaciais do Cerrado de diferentes anos. Após a leitura desses arquivos com o pacote "sf", foram selecionadas as colunas de interesse: "state", "area_km", "year" e "image_date". A coluna "state", que originalmente era uma variável categórica representando os estados, foi transformada em um conjunto de variáveis binárias. A partir da coluna "image_date", foram criadas colunas para representar o mês e o dia com intuito posterior de agrupar os dados mensalmente e bimestralmente.

Mais adiante, com a finalidade de se obter um entendimento melhor sobre os dados foram calculadas as estatísticas descritivas para as variáveis métricas do conjunto de dados, ilustradas pela Tabela 2:

Tabela 2. Estatísticas descritivas do conjunto de dados

Variável	year	Mês	area_km
Média	2013,79	7,71	423,94
Mediana	2014	8	150,23
Min	2004	1	0,03
Max	2023	12	5738,71
Desvio Padrão	5,52	1,43	699,91
Coef. Variação (%)	0,27	18,58	165,10

Fonte: Dados originais da pesquisa

Por essa tabela nota-se que a área desmatada possui um alto coeficiente de variação e uma diferença muito grande entre seu máximo e mínimo, o que sugere uma investigação detalhada acerca de seu comportamento. Dessa forma, com a finalidade de analisar a distribuição de frequências da variável área desmatada em km², que será nossa variável alvo, foi construído o histograma disposto na Figura 2:




Figura 2. Gráfico Histograma da variável área desmatada

Fonte: Dados originais da pesquisa

Observando o histograma nota-se que a variável em questão possui uma distribuição assimétrica e com superdispersão. Para dar sequência na caracterização da série histórica abordada, foi então gerado um gráfico da variável alvo ao longo do tempo (Figura 3), com intuito de nos fornecer informações acerca de componentes de sazonalidade e ou tendência.




Figura 3. Gráfico da variável area_km ao longo do tempo
Fonte: Dados originais da pesquisa

Ao visualizar a Figura 3 evidencia-se que há certo grau de sazonalidade nos dados, portanto, para investigar mais a fundo, foi criada a coluna “sazonalidade” representada pelas categorias: verão (dez-fev), outono (mar-mai), inverno (jun-ago) e primavera (set-nov). A partir disso foi elaborado o gráfico da Figura 4 que contém a soma de área desmatada por estação do ano.




Figura 4. Gráfico de área desmatada por estação
Fonte: Dados originais da pesquisa

Retornando a analisar a Figura 3, percebe-se que há também certa tendência na série histórica, o que sugere a criação de um componente capaz de captar essa característica. Portanto, a fim de obter um componente de tendência para os modelos, foi calculada a média móvel, incluindo todos os estados, dos últimos 12 meses, representada

pela coluna “media_movel_12”. A seguir é ilustrado o seu gráfico ao longo do tempo (Figura 5):




Figura 5. Gráfico da variação percentual da area_km ao longo do tempo
Fonte: Dados originais da pesquisa

Com o objetivo de aprofundar a análise sobre a dinâmica espacial do desmatamento, torna-se necessário investigar a regionalidade como um fator relevante no comportamento do desmatamento no Cerrado. Desse modo, foi construído um gráfico com o acumulado da área desmatada por estado (Figura 6), buscando identificar se há estados que concentram uma maior parte das áreas afetadas e comparando o impacto do desmatamento em diferentes localidades durante o período abordado.




Figura 6. Gráfico da variação percentual da area_km ao longo do tempo
Fonte: Dados originais da pesquisa

O gráfico revela uma distribuição desigual da área desmatada entre os estados do Cerrado, com Tocantins, Maranhão e Goiás apresentando os maiores valores acumulados. Esse padrão sugere que certas regiões são significativamente mais impactadas pelo desmatamento, possivelmente devido a fatores como uso do solo, políticas ambientais locais ou atividades econômicas predominantes. Por outro lado, estados como Paraná, São Paulo e Rondônia exibem valores substancialmente menores, indicando uma menor pressão sobre a vegetação nativa nesses locais. Essa disparidade reforça a importância de uma abordagem regionalizada.

Ao analisar todos esses gráficos em questão, nota-se um padrão intrigante na dinâmica da área desmatada no Cerrado. O histograma (Figura 2) revela uma distribuição conhecida como distribuição assimétrica à direita, sugerindo a presença de outliers e a necessidade de um entendimento mais aprofundado sobre as causas desse desmatamento. Já o gráfico da evolução da área desmatada ao longo do tempo (Figura 3) demonstra flutuações significativas, com picos notáveis frequentemente, evidenciando a ocorrência de sazonalidade e possíveis eventos que influenciam o desmatamento. O gráfico que ilustra o total de área desmatada por sazonalidade (Figura 4) confirma a presença de sazonalidade da série histórica ao demonstrar que o inverno é significativamente a estação com o maior total de desmatamento. Isso sugere que fatores climáticos, como a temperatura e a umidade do ar, podem ter um papel preponderante na quantidade de desmatamento que ocorre durante o ano. Portanto, com intuito de obter mais variáveis significativas para a predição, foi coletado no banco de dados meteorológicos do Instituto Nacional de Meteorologia [INMET] variáveis ambientais como: precipitação total diária (mm), umidade média diária do ar (%), temperatura média diária (°C) e velocidade média diária do vento (m/s). Esses dados são provenientes de todas estações meteorológicas automáticas, logo precisaram ser agrupados por mês e unidade federativa, sendo agregados pela função média para serem inseridos corretamente no “dataset” de trabalho. Além disso, foi coletado também o número de focos de queimadas por ano e mês no bioma do Cerrado pelo portal TerraBrasilis. Para averiguar a relação das queimadas com o desmatamento foi elaborado um gráfico comparativo do acumulado mensal das duas variáveis (Figura 7).




Figura 7. Gráfico comparativo entre queimadas e desmatamento
Fonte: Dados originais da pesquisa

A análise da relação entre a área desmatada e o número de focos de queimadas, conforme ilustrado na Figura 7, revela um padrão significativo: as queimadas frequentemente ocorrem como um fenômeno subsequente ao desmatamento. Observa-se que os meses com maior registro de desmatamento precedem picos consideráveis no número de focos de queimada. Essa sequência sugere que, após a remoção da vegetação, a área desmatada é frequentemente sujeita a práticas de queima. Desse modo, devido ao fenômeno das queimadas ser posterior ao desmatamento, impossibilitando que normalmente seja utilizado para prever seu valor, será considerado como variável de entrada o N° de focos de queimadas com atraso de 10 períodos.

Com todas essas novas variáveis no “dataset” de trabalho obteve-se um novo quadro de estatísticas descritivas (Tabela 3) a fim de as entender melhor.

Tabela 3. Estatísticas descritivas das novas variáveis

Variável	Precipitacao	Temperatura	Umidade	Vel_Vento	queimadas_lag	media_movel_12
Média	1,09	24,04	61,03	1,94	12697,85	2631,9
Mediana	0,58	24,66	61,52	1,87	10815,00	2124,47
Min	0	15,21	32,55	0,86	376	691,25
Max	12,02	30,65	82,39	5,72	49980	8472,26
Desvio	1,47	3,3	10,2	0,51	9992,51	1682,85
Padrão						
Coef.	134,25	13,74	16,71	26,12	78,69	63,94
Varição (%)						

Fonte: Dados originais da pesquisa

Para verificar a adequação das variáveis ao problema e investigar a correlação entre as variáveis de entrada e a variável alvo, foi elaborado um modelo linear como etapa inicial. Esse modelo teve como objetivo explorar a relação entre a área desmatada (variável alvo) e as variáveis explicativas previamente abordadas. A escolha de um modelo linear foi motivada por sua simplicidade, permitindo interpretar de forma clara a força e a direção das relações entre as variáveis, além de oferecer uma linha de base para comparações com modelos mais complexos. Por meio desse modelo, foi possível identificar padrões iniciais, como a relevância das variáveis de sazonalidade e tendência, que serviram como insumos fundamentais para o refinamento dos modelos preditivos subsequentes e a confirmação da adequação das variáveis ao problema estudado. O resumo deste modelo linear está ilustrado na Tabela 4.

Tabela 4. Resumo modelo linear

Variável (Coluna)	Estatística t	p -valor
Intercepto	1,12	$2,64 \cdot 10^{-01}$
media_movel_12	6,07	$2,25 \cdot 10^{-09}$
sazonalidadeoutono	0,78	$4,34 \cdot 10^{-01}$
sazonalidadeprimavera	-3,98	$7,64 \cdot 10^{-05}$
sazonalidadeverao	-1,09	$2,78 \cdot 10^{-01}$
stateGOIÁS	-1,14	$2,54 \cdot 10^{-01}$
stateBAHIA	-0,29	$7,73 \cdot 10^{-01}$
stateDISTRITO FEDERAL	-3,54	$4,31 \cdot 10^{-04}$
statePARANÁ	-1,35	$1,78 \cdot 10^{-01}$
stateMATO GROSSO	-1,36	$1,75 \cdot 10^{-01}$
stateMATO GROSSO DO SUL	-2,07	$3,93 \cdot 10^{-02}$
stateMINAS GERAIS	-0,35	$7,29 \cdot 10^{-01}$
stateTOCANTINS	-0,54	$5,92 \cdot 10^{-01}$
stateSÃO PAULO	-2,20	$2,84 \cdot 10^{-02}$
stateRONDÔNIA	-5,91	$5,81 \cdot 10^{-09}$
statePIAUÍ	-4,53	$6,97 \cdot 10^{-06}$
statePARÁ	-4,36	$1,55 \cdot 10^{-05}$
year	-1,08	$2,80 \cdot 10^{-01}$
periodo	0,81	$4,18 \cdot 10^{-01}$
Precipitacao	-0,05	$9,57 \cdot 10^{-01}$
Temperatura	0,81	$4,21 \cdot 10^{-01}$
Umidade	-4,12	$4,29 \cdot 10^{-05}$
Velocidade_Vento	0,45	$6,51 \cdot 10^{-01}$
queimadas_lag	5,28	$1,83 \cdot 10^{-07}$
Estatística F	14,58	$< 2,2 \cdot 10^{-16}$
R ² (Coeficiente de Determinação)	35,47%	
RMSE	561,79	
MAE	361,06	
MAPE	15327,90 %	

Fonte: Resultados originais da pesquisa

Tais resultados do modelo linear oferecem percepções importantes sobre as relações entre as variáveis explicativas e a área desmatada. A variável "media_movel_12"

destacou-se como altamente significativa, indicando que a tendência histórica exerce forte influência sobre o desmatamento. Da mesma forma, as categorias de sazonalidade apresentaram significância estatística, sugerindo que os padrões sazonais afetam diretamente os níveis de desmatamento. No entanto, apesar de a estatística F indicar que o modelo é globalmente significativo, o coeficiente de determinação R^2 de 35,47% revela que, embora o modelo explique uma parcela relevante da variabilidade nos dados, grande parte do comportamento do desmatamento ainda não é capturada por essas variáveis. Isso sugere a necessidade de modelos mais robustos e complexos, capazes de incorporar não linearidades e interações entre variáveis, como redes neurais e florestas aleatórias, para uma análise mais aprofundada e preditiva.

Além do modelo linear e a fim de evitar o problema de multicolinearidade, ou seja, quando variáveis preditoras possuem forte correlação entre si, foi elaborada com “software” R uma matriz de correlação entre as variáveis métricas preditoras (Figura 8).




Figura 8. Matriz de correlação entre as variáveis métricas do conjunto de dados
Fonte: Resultados originais da pesquisa

A matriz de correlação apresentada na Figura 8 evidencia as relações entre as variáveis explicativas e oferece percepções importantes para o refinamento dos modelos preditivos. Nota-se uma forte correlação negativa entre as variáveis "year" e "media_movel_12", indicando que a tendência histórica capturada por "media_movel_12" já incorpora boa parte da informação contida em "year", o que sugere cuidado ao seu uso

simultâneo nos modelos. Além disso, as variáveis meteorológicas, como "Precipitação" e "Umidade", apresentam correlações significativas entre si, reforçando a necessidade de atenção ao seu uso conjunto nos modelos. Por fim, a baixa correlação direta entre a maioria das variáveis meteorológicas e a "area_km" indica que essas variáveis, embora relevantes, podem necessitar de interações com outras para capturar melhor a complexidade do desmatamento, destacando a importância de modelos mais sofisticados para análise e predição. Para complementar a análise do modelo linear, foi construído um gráfico de valores ajustados ("fitted values") comparando as previsões do modelo com os valores reais (Figura 9).




Figura 9. Gráfico de valores ajustados do modelo linear

Fonte: Resultados originais da pesquisa

A Figura 9 ilustra o desempenho do modelo linear ao comparar os valores reais com os valores preditos, utilizando uma linha de referência (em verde), simbolizando o caso ideal em que as previsões seriam idênticas aos valores reais. Observa-se que os pontos azuis, representando as previsões do modelo, apresentam uma certa dispersão em torno da linha ideal, indicando que o modelo captura parcialmente a relação entre as variáveis explicativas e o desmatamento, mas ainda existem erros residuais significativos.

Adicionalmente, a linha laranja, que representa a tendência predita pelo modelo, demonstra um ajuste que diverge da linha ideal em diferentes intervalos do eixo X. Essa discrepância é mais evidente para valores extremos de área, onde o modelo tende a subestimar as áreas maiores e a superestimar as menores. Esse padrão reforça a necessidade de explorar abordagens mais robustas, como modelos não lineares ou

interações complexas entre variáveis, para capturar a complexidade intrínseca dos fatores que influenciam o desmatamento.

Diante disso, para a preparação dos dados para os modelos subsequentes, algumas etapas de manipulação foram realizadas, incluindo normalização, divisão dos conjuntos de treino e teste e uma transformação logarítmica foi aplicada à variável alvo, "area_km", para diminuir os efeitos de valores extremos. A normalização das variáveis numéricas foi realizada utilizando a função "scale" do pacote base do R, ajustando os dados para uma distribuição normal com média 0 e desvio padrão 1. A abordagem para a divisão dos conjuntos variou conforme o modelo: na "Random Forest" e na Rede Neural "Feedforward", foi utilizada uma divisão aleatória tradicional, também na proporção de 80% para treino e 20% para teste. Para a Rede Neural Recorrente, os dados foram divididos em 80% para treino e 20% para teste, sendo ordenados temporalmente e organizados em lotes ("batches") com dimensões específicas para o treinamento. Além disso, é importante mencionar que as variáveis categóricas para os modelos de redes neurais tiveram que ser codificadas binariamente, já para a RF foi preciso apenas transformá-las no tipo de dado "factor", pois ela já trata os níveis do "factor" como categorias distintas, sem supor qualquer relação de ordem. Ademais, é importante ressaltar que os dados foram testados em agrupamentos mensais, como no modelo linear inicial, e bimestrais, este último com o intuito de reduzir a alta variância dos dados e identificar padrões mais consistentes no conjunto. No entanto, essa abordagem reduziu o número de observações de 634 para apenas 399.

Redes Neurais

Segundo Ferneda (2006), as redes neurais são modelos matemáticos inspirados no funcionamento do cérebro humano, sendo compostas por unidades de processamentos simples, os neurônios, que se unem por meio de conexões sinápticas. De uma forma simplificada, uma rede neural pode ser vista como um grafo onde os nós são os neurônios e as ligações fazem a função das sinapses (Ferneda, 2006), como exemplificado na Figura 10:




Figura 10. Diagrama simplificado de uma rede neural artificial

Fonte: <https://www.monolitonimbus.com.br/redes-neurais-artificiais/> acesso em: 06 abr. 2024

Existem três tipos principais de camadas em uma rede neural: camada de entrada, camadas ocultas e camada de saída. Camada de entrada: a camada de entrada é a primeira camada da rede neural, onde os dados de entrada são introduzidos. Cada neurônio nesta camada representa uma característica específica dos dados de entrada. Cada neurônio na camada de entrada está conectado a todos os neurônios da próxima camada, conhecida como camada oculta. Camadas ocultas: as camadas ocultas estão localizadas entre a camada de entrada e a camada de saída. Essas camadas processam as informações dos neurônios de entrada e transmitem os resultados para a camada de saída. Cada neurônio em uma camada oculta realiza uma combinação linear das entradas ponderadas pelos pesos sinápticos, seguida de uma função de ativação não linear, como a função sigmóide (logística), tangente hiperbólica ou ReLU ("Rectified Linear Unit"). As camadas ocultas são responsáveis por aprender e extrair características importantes dos dados de entrada. Camada de saída: a camada de saída é a última camada da rede neural, onde as previsões ou saídas são geradas. Cada neurônio na camada de saída também aplica uma função de ativação. Conexões ponderadas: cada conexão entre neurônios em camadas adjacentes tem um peso associado que determina a força da conexão entre eles. Durante o treinamento da rede neural, os pesos são ajustados iterativamente por meio de algoritmos de otimização, como o gradiente descendente, com o objetivo de minimizar uma função de perda que quantifica o erro entre as previsões da rede e os rótulos reais dos dados.

Uma das propriedades mais importantes de uma rede neural artificial é a capacidade de aprender por intermédio de exemplos e fazer inferências sobre o que aprendeu, melhorando gradativamente o seu desempenho (Ferneda, 2006). As redes neurais utilizam um algoritmo de aprendizagem cuja tarefa é ajustar os pesos de suas conexões (Braga et al, 2000).

A otimização dos modelos de redes neurais foi realizada pela alteração de parâmetros, tais como o número de neurônios em cada camada, número de épocas, a função de ativação, a taxa de aprendizado e o método de otimização, visando maximizar a performance dos modelos na previsão do desmatamento no conjunto teste.

Redes Neurais Recorrentes

Foi utilizada, também, outro tipo de rede neural chamada rede neural recorrente. Essas redes possibilitam que as ligações entre neurônios formem ciclos, conhecidos como conexões recorrentes, que por sua vez, permitem que seu estado interno mantenha um “vetor de estado” que contém implicitamente informações sobre a história de todos os elementos passados da sequência (Santana, 2017). A Figura 11 ilustra bem essa característica. Por terem essa capacidade de manter uma memória, elas são especialmente adequadas para processar dados sequenciais, como séries temporais, texto e áudio.




Figura 11. Rede neural recorrente

Fonte: <https://www.deeplearningbook.com.br/redes-neurais-recorrentes/> acesso em: 09 abr. 2024

Para essas redes existem diferentes arquiteturas. Elman (1990) e Jordan (1986) propuseram duas redes, as quais diferem fundamentalmente na ligação da recorrência. A rede Elman, utiliza conexões da camada oculta para fazer a realimentação para uma unidade de contexto, uma camada com neurônios adicionais que representam uma unidade interna, já a rede Jordan utiliza os sinais da camada de saída para a unidade de contexto, ou seja, a conexão recorrente permite que a camada intermediária da rede acesse sua saída anterior (Santana, 2017). No contexto deste trabalho, a rede utilizada é uma rede Elman, implementada através do pacote “rnn” do R, que adota essa arquitetura específica.

Segundo Santana (2017), o aprendizado com redes recorrentes tem sido considerado um desafio devido à dificuldade de aprender dependências de longo alcance, pois, em redes com múltiplas camadas, ocorrem os problemas chamados desaparecimento

(“vanishing”) ou explosão (“exploding”) do gradiente durante a retropropagação do erro. Tais eventos acontecem devido ao rápido crescimento, no caso da explosão, ou decaimento, no caso do desaparecimento, do gradiente durante a retropropagação do erro (Santana, 2017), o que dificulta uma atualização precisa dos pesos nas camadas iniciais da rede.

De acordo com Santana (2017), uma solução para este problema consiste na utilização de uma nova arquitetura RNN denominada “Long Short-Term Memory” [LSTM], a qual possui uma capacidade de armazenar informações por um período mais longo de tempo. Outra arquitetura desenvolvida posteriormente a Elman e Jordan foi a “Gated Recurrent Unit” [GRU] que, assim como a LSTM, possui a capacidade de armazenar informações por um período mais longo de tempo.

Como foi apresentado, existem diversos tipos de redes recorrentes, nesta pesquisa, no entanto, foram exploradas a utilização de apenas 3 delas, sendo a rede de Elman, a LSTM e a GRU, que são representadas respectivamente pelos valores “rnn”, “lstm” e “gru” no argumento “network_type” da função “trainr” do pacote “rnn”.

A otimização destas redes na pesquisa foi realizada alterando manualmente, parâmetros como o número de neurônios em cada camada (hidden), tipo de arquitetura (“lstm”, “gru” ou “rnn”), número de épocas, a função de ativação e a taxa de aprendizado, visando maximizar a performance dos modelos perante os critérios estatísticos de avaliação (RMSE, R^2 , MAPE e MAE).

Random Forest

Além das redes neurais, a “random forest” foi explorada como outra abordagem de aprendizado de máquina para prever o desmatamento no bioma do Cerrado. As florestas aleatórias consistem em um conjunto de árvores de decisão construídas a partir de subconjuntos aleatórios dos dados de treinamento (“bagging”), de modo a combinar múltiplos modelos para melhorar a precisão e robustez das previsões. Segundo Garcia (2003), árvores de decisão são uma forma simples e eficaz de representar o conhecimento. Uma árvore de decisão utiliza uma estratégia de dividir para-conquistar: um problema complexo é decomposto em subproblemas mais simples. Recursivamente a mesma estratégia é aplicada a cada subproblema (Crepaldi et al., 2012). Ainda segundo Crepaldi et al. (2012), as árvores de decisão são compostas por nós, que representam decisões, interconectados por ramos que representam as diferentes alternativas para uma decisão particular, como exemplificado na Figura 12. Assim, por meio das decisões pode-se chegar às probabilidades de cada resultado e traçar uma solução do problema.

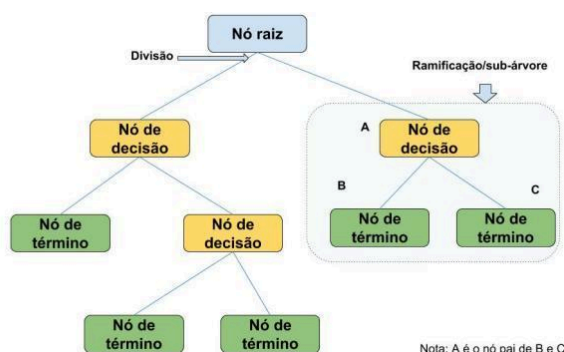


Figura 12. Diagrama simplificado de uma árvore de decisão

Fonte:

<https://www.vooo.pro/insights/um-tutorial-completo-sobre-a-modelagem-baseada-em-tree-arvore-do-zero-em-r-python/> acesso em: 06 abr. 2024

Foram explorados diferentes parâmetros das florestas aleatórias, como o número de árvores na floresta e o número de variáveis consideradas em cada nó da árvore, a fim de determinar a configuração ótima do modelo. Assim como nas redes neurais, a performance da RF foi avaliada utilizando métricas estatísticas como o coeficiente de determinação, o erro absoluto médio, o erro percentual médio absoluto e a raiz do erro quadrático médio.

Resultados e Discussão

Rede Neural Feedforward

Para a modelagem utilizando a Rede Neural Feedforward, os dados foram primeiramente divididos em conjuntos de treino e teste, sendo 80% dos dados alocados para treino e 20% para teste. Essa divisão foi realizada de maneira aleatória, garantindo que a amostra representasse uma variedade de condições do conjunto de dados. A preparação dos dados incluiu a normalização das variáveis numéricas, bem como a transformação das variáveis categóricas em variáveis “dummy”.

Na fase de modelagem, foi adotado o pacote “neuralnet” para construir a rede neural. Foram obtidos diversos resultados variando parâmetros como: variáveis explicativas; número de neurônios das camadas escondidas; “learning rate”; critério de convergência e função de ativação dos neurônios. O melhor deles, conforme os critérios estatísticos citados anteriormente, está disposto na Tabela 5:

Tabela 5. Resultados para a Rede Neural Feedforward

Parâmetros da Rede	Métricas de avaliação no conjunto teste			
	R ²	RMSE	MAE	MAPE
Variáveis explicativas				
year , periodo , queimadas_lag , media_movel_12 , state, sazonalidade	49,13%	536,07	270,95	3616,36%
Hiperparâmetros				
hidden = c(3), act.fct = "logistic", threshold = 0.05, learningrate = 0.5				

Fonte: Resultados originais da pesquisa

Esses resultados demonstram a capacidade da rede de identificar padrões relevantes nas variáveis de entrada e sua relevância em modelar a área desmatada. Apesar do R² não ser elevado, a rede mostrou potencial ao capturar nuances complexas na relação entre as variáveis independentes e a variável dependente, oferecendo uma alternativa viável a métodos mais tradicionais de modelagem. No entanto, seu alto valor de MAPE sugere uma maior investigação da performance do modelo, para isso foi elaborado o gráfico de valores ajustados que compara os valores reais da variável resposta com as previsões feitas pelo modelo (Figura 13)




Figura 13. Gráfico de valores ajustados da FNN

Fonte: Resultados originais da pesquisa

O modelo mostra uma boa correspondência nos valores baixos, com os pontos se concentrando próximos à linha de identidade (verde), especialmente na região onde a maioria dos dados está agrupada. Essa proximidade sugere que o modelo captura bem o

comportamento geral da variável resposta nessa faixa. No entanto, à medida que os valores reais aumentam, fica evidente o maior erro nas previsões. Esse comportamento é consistente com a presença de uma distribuição assimétrica na variável resposta. Como valores extremos são escassos, eles têm menor impacto no treinamento do modelo, resultando em uma capacidade limitada para prever esses casos de maneira precisa.

Já com o agrupamento bimestral, o resultado foi melhor, devido provavelmente a padrões mais consistentes, menor variabilidade e menos lacunas nas observações. Para esta abordagem, também foram explorados novamente os valores dos parâmetros e a seleção das variáveis. A seguir é evidenciado os resultados da FNN para um agrupamento bimestral (Tabela 6).

Tabela 6. Resultados para a Rede Neural Feedforward com dados bimestrais

Parâmetros da Rede	Métricas de avaliação no conjunto teste			
	R ²	RMSE	MAE	MAPE
Variáveis explicativas				
year, periodo, Precipitacao, Temperatura, Velocidade_Vento, queimadas_lag, media_movel_12, state, sazonalidade	56,07%	606,45	300,92	345,73
Hiperparâmetros				
hidden = c(2), act.fct = "logistic", threshold = 0.05, learningrate = 0.5				

Fonte: Resultados originais da pesquisa

Esses resultados indicam que a agregação bimestral contribuiu para uma melhora na performance do modelo, refletida pelo aumento no R² e pela redução no MAPE. Nota-se que, apesar do aumento no RMSE, a redução expressiva no MAPE indica que o modelo teve um desempenho mais equilibrado ao longo da distribuição dos dados. Essa abordagem reforça a importância da granularidade temporal na modelagem, permitindo que o modelo capture padrões subjacentes com maior precisão.

Rede Neural Recorrente

Para a concepção das Redes Neurais Recorrentes (RNNs), foram criadas duas colunas de “lag” (“arealog_lag”, “arealog_lag2”), representando atrasos de um e dois períodos, respectivamente, para servirem como variáveis de entrada no modelo. Após isso, foi aplicado o processo de padronização, garantindo que as variáveis numéricas tivessem média zero e desvio padrão igual a um, com intuito de melhorar a performance. Os dados foram então divididos em conjuntos de treino e teste, respeitando uma proporção de 80% para treino e 20% para teste, e ajustados ao formato exigido pelas RNNs, sendo organizados em lotes (“batches”) com dimensões específicas para alimentar o modelo. O

modelo foi então treinado por uma grade de hiperparâmetros buscando a melhor combinação entre: tamanho do lote (“batch_size”); escolha das variáveis de entrada; número de neurônios da camada escondida (“hidden_dim”); taxa de aprendizado (“learning rate”); número de épocas (“numepochs”); tipo de rede (“rnn”, “lstm” ou “gru”) e a função sigmoid (“logistic”, “Gompertz” ou “tanh”). Com isso, utilizando primeiro a função “predictr” e depois desnormalizando os resultados, pode-se prever para o conjunto teste os valores da área desmatada em km², as quais foram avaliadas, obtendo os resultados encontrados na Tabela 7. Ademais, é importante mencionar que o modelo da RNN foi treinado com a abordagem bimestral, pois com os dados mensais não foram obtidos resultados satisfatórios.

Tabela 7. Resultados para a Rede Neural Recorrente com dados bimestrais

Parâmetros da Rede	Métricas de avaliação no conjunto teste			
	R ²	RMSE	MAE	MAPE
Variáveis explicativas				
year, periodo, Precipitacao, Temperatura, Velocidade_Vento, queimadas_lag, arealog_lag, arealog_lag2, media_movel_12, state, sazonalidade	57,99%	804,62	1058,44	381.73
Hiperparâmetros				
hidden_dim= c(3), sigmoid = "Gompertz", network_type = “rnn”, loss_function = loss_L1, momentum= 0.95, learningrate = 0.1				

Fonte: Resultados originais da pesquisa

Embora a Rede Neural Recorrente, tenha apresentado um R² ligeiramente superior ao da Feedforward Neural Network, sua performance geral não foi necessariamente melhor quando analisada sob o conjunto completo de métricas. O RMSE e o MAE foram consideravelmente mais altos na RNN, indicando que os erros absolutos nas previsões foram maiores, o que compromete sua precisão prática. Além disso, o MAPE da RNN também foi significativamente mais elevado, demonstrando dificuldades na previsão proporcional dos valores da variável resposta. Esse desempenho pode estar relacionado à característica das RNNs de exigirem grandes volumes de dados para treinamento eficaz, o que não foi o caso neste estudo, dado que o conjunto de dados utilizado era relativamente pequeno, com apenas 399 observações. A limitação no tamanho dos dados pode ter impactado a capacidade da RNN de generalizar padrões temporais de forma mais eficiente. Para ilustrar esse desempenho visualmente, foi elaborado novamente o gráfico de valores ajustados, desta vez, para a RNN (Figura 14).




Figura 14. Gráfico de valores ajustados da RNN
Fonte: Resultados originais da pesquisa

A figura acima revela um comportamento semelhante ao observado no gráfico correspondente ao modelo de FNN, mas com uma diferença notável: as previsões geradas pela RNN estão ainda mais distantes da diagonal ideal, além de uma maior concentração de pontos à direita. Esse padrão indica uma tendência de subestimação nas previsões da RNN, em comparação com a FNN, que apresentava uma distribuição mais equilibrada de pontos, incluindo uma quantidade ligeiramente maior à esquerda. Essa concentração desigual sugere que o modelo RNN enfrenta desafios adicionais para generalizar padrões temporais de forma eficaz.

Random Forest

Para a RF, inicialmente, os dados foram divididos aleatoriamente na proporção de 80% para treino e 20% para teste. Para isso, foi utilizado o método de validação cruzada "cv". A configuração do método envolveu um número de 4 "folds". Isso garante que o modelo seja treinado em diferentes subconjuntos dos dados e avaliado em dados distintos a cada iteração, refletindo um cenário mais realista de validação, onde o modelo é testado em diferentes partes do conjunto de dados ao longo do processo.

Na etapa de modelagem, foi utilizado o pacote "caret" para ajustar o modelo de "Random Forest". A otimização do modelo foi realizada por meio de uma grade de parâmetros, onde o número de variáveis consideradas em cada nó da árvore ("mtry") foi ajustado para valores de 1 a 7, o número de árvores foi definido como 500, garantindo

robustez e maior estabilidade no modelo final. Os melhores resultados obtidos, testando todas as combinações de variáveis, estão expostos na Tabela 8.

Tabela 8. Resultados para a random forest

Variáveis explicativas	Métricas de avaliação no conjunto teste			
	R ²	RMSE	MAE	MAPE
year, periodo, state, Velocidade_Vento, queimadas_lag, media_movel_12	58,29%	577,11	278,70	2493,52%
year, periodo, sazonalidade, state, Velocidade_Vento, queimadas_lag, media_movel_12	55,20%	591,51	283,02	2387,78%
year, periodo, state, Velocidade_Vento, queimadas_lag	55,90%	585,62	277,98	2778,21%
Média	56,46%	584,75	279,90	2553,17%

Fonte: Resultados originais da pesquisa

Os resultados obtidos com o “Random Forest” revelaram não apenas a relevância das características temporais e sazonais, como o ano, o mês e a estação do ano, mas também a influência significativa das condições regionais, representadas pelo estado, no impacto sobre a área desmatada. Essa abordagem permitiu identificar relações não lineares e interações complexas entre os fatores, algo difícil de capturar com métodos mais simples. Além disso, foi elaborada a análise de importância das variáveis oferecida pelo “caret” com a função “varImp” (Figura 15).

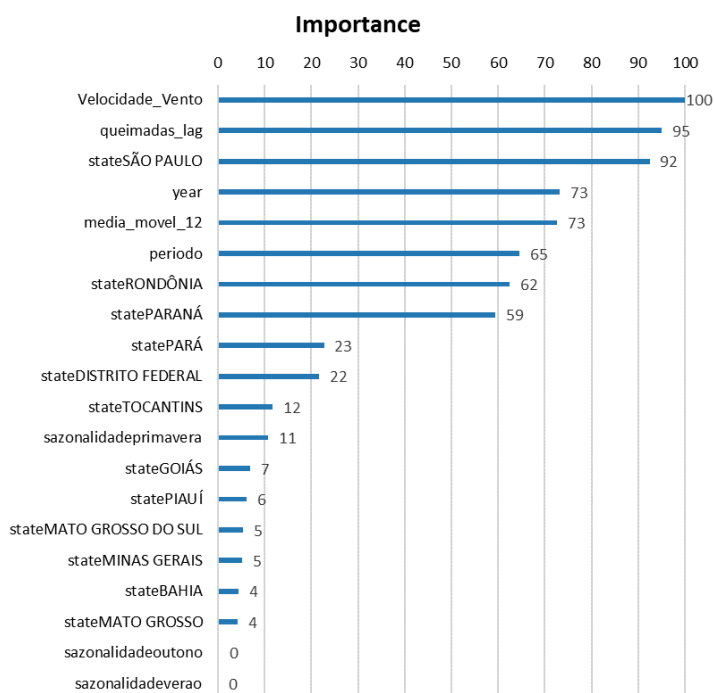


Figura 15. Importância das variáveis para a “Random Forest”

Fonte: Resultados originais da pesquisa

O gráfico de importância das variáveis destaca a influência relativa de cada um dos fatores considerados no modelo de “Random Forest”. A velocidade do vento, com a maior pontuação, evidencia sua influência, sugerindo que condições climáticas adversas podem acelerar a degradação florestal. A variável “queimadas_lag”, com uma pontuação próxima, ressalta a relação estreita entre eventos de queimadas e o desmatamento. Outros elementos, como o estado de São Paulo e a medida temporal “year”, importantes na pontuação, destacam a importância do contexto regional e das tendências ao longo do tempo.

Para visualizar graficamente a performance do modelo, foi gerado um gráfico de valores ajustados (“Fitted Values”), onde se comparou os valores reais da variável resposta com as previsões feitas pelo modelo (Figura 16). Esse gráfico evidencia o alinhamento ou não entre as previsões e os dados observados. Uma forte concordância seria indicada pelos pontos se concentrando ao longo da linha de identidade ($Y = X$). Esse tipo de análise fornece percepções importantes sobre os casos em que o modelo tem maior precisão, bem como potenciais discrepâncias que podem indicar limitações ou a necessidade de ajustes adicionais na modelagem.




Figura 16. Gráfico de valores ajustados da RF

Fonte: Resultados originais da pesquisa

Com base na figura apresentada, observa-se que o modelo apresenta uma tendência razoável de alinhamento entre os valores preditos e os valores reais para a variável resposta, especialmente em faixas de valores mais baixos, onde a maior densidade de pontos se aproxima da linha de identidade ($Y = X$). No entanto, é possível identificar uma

dispersão significativa à medida que os valores reais aumentam, evidenciada por pontos que se afastam da linha de tendência ideal, sobretudo nas regiões de valores mais altos da variável resposta. A linha de tendência do modelo, representada em laranja, destaca uma subestimação sistemática dos valores mais elevados, indicando que o modelo apresenta dificuldades em capturar com precisão os extremos do desmatamento. Essa característica pode estar associada à distribuição altamente assimétrica dos dados, onde valores de alta magnitude são raros e exercem menor influência na construção do modelo.

Além destes resultados, obteve-se os com agrupamento bimestral, que gerou melhores pontuações, devido provavelmente a padrões mais consistentes, menor variabilidade e menos lacunas nas observações. Para esta abordagem, foram explorados novamente os valores dos parâmetros e a seleção das variáveis. A seguir é evidenciado os resultados da RF para um agrupamento bimestral (Tabela 9).

Tabela 9. Resultados para a random forest com dados bimestrais

Variáveis explicativas	Métricas de avaliação no conjunto teste			
	R ²	RMSE	MAE	MAPE
year, periodo, sazonalidade, state, Velocidade_Vento, queimadas_lag, media_movel_12	71,56%	576,11	266,29	292,59

Fonte: Resultados originais da pesquisa

Os resultados obtidos com a abordagem de agrupamento bimestral para o modelo de Random Forest demonstraram uma melhoria significativa nas métricas de avaliação em comparação com as análises anteriores. Com um R² de 71,56%, o modelo exibe um aumento considerável na capacidade explicativa, refletindo uma melhor compreensão das variáveis que influenciam o desmatamento. Adicionalmente, o RMSE e o MAE apresentaram valores de 576,11 e 266,29, respectivamente, indicando uma redução nos erros de previsão e, consequentemente, uma maior precisão no ajuste do modelo. O MAPE de 292,59% também sugere que, ao segmentar os dados em períodos bimestrais, foram identificados padrões mais consistentes e com menos variação, proporcionando uma base mais robusta para a modelagem e possibilitando uma melhor interpretação das dinâmicas do desmatamento.




Figura 17. Gráfico de valores ajustados da RF com dados bimestrais
Fonte: Resultados originais da pesquisa

Na análise gráfica apresentada, observa-se que o gráfico de valores ajustados do modelo Random Forest ilustra, novamente, a tendência de conformidade razoável entre as previsões e os valores reais da variável resposta em faixas de valores mais baixos. Contudo, à medida que os valores reais aumentam, nota-se novamente uma maior dispersão dos pontos, indicando dificuldades na previsão de valores extremos de desmatamento. A linha de tendência do modelo, destacada em laranja, revela uma subestimação, assim como nos modelos anteriores, no entanto, mais leve, em relação aos valores mais elevados, o que pode ser atribuído à distribuição assimétrica dos dados. Essa análise enfatiza a importância de otimizações adicionais e da consideração de interações mais complexas entre variáveis, particularmente para valores extremos, que são cruciais para uma compreensão mais abrangente do fenômeno do desmatamento.

Discussão sobre os modelos

Os resultados obtidos indicam diferenças significativas no desempenho dos modelos, sendo a floresta aleatória o que apresentou o melhor desempenho, com um coeficiente de determinação (R^2) de 71%, o que indica que o modelo foi capaz de explicar 71% da variabilidade dos dados. Esse resultado sugere que, apesar de não alcançar uma performance de ajuste excepcional, o modelo foi relativamente eficaz em capturar a relação entre as variáveis independentes e a variável resposta. Além disso, seus valores de RMSE (576,11) e MAE (266,29) demonstraram que as previsões foram, em média, mais precisas em comparação com as outras abordagens.

Por outro lado, as demais redes neurais tiveram desempenhos significativamente inferiores. Os índices de R^2 da FNN e da RNN indicam que os modelos conseguiram explicar uma parcela boa da variabilidade dos dados, no entanto, bem inferiores quando comparados ao melhor resultado da RF. Além disso, as demais métricas mostram que, além da captura inferior da variabilidade dos dados, os modelos tiveram previsões, em média, menos precisas que o modelo da RF. Diante disso, para o melhor modelo obtido (RF com agrupamento bimestral), foi gerado o gráfico das previsões da série histórica ao longo do tempo (Figura 18), com intuito de analisar visualmente como o modelo obtido se comporta em relação ao esperado.




Figura 18. Gráfico do melhor modelo ao longo do tempo
Fonte: Resultados originais da pesquisa

A análise visual da Figura 18 reforça os achados estatísticos, evidenciando que o modelo RF conseguiu captar com razoável precisão os padrões temporais da série histórica. Observa-se que as previsões (linha azul tracejada) acompanham de perto as oscilações da série real (linha verde contínua), especialmente nos períodos de alta variação, sugerindo que o modelo consegue identificar as tendências sazonais presentes nos dados. No entanto, em alguns picos de desmatamento, nota-se uma subestimação das previsões, indicando que o modelo pode ter dificuldades em capturar eventos extremos com a mesma acurácia que os períodos de menor variação. Ainda assim, a proximidade entre as linhas sugere que o modelo apresenta um desempenho consistente ao longo do tempo.

Considerações Finais

Sob essa ótica, esses resultados sugerem que, apesar do potencial teórico das redes neurais recorrentes, a natureza dos dados e a limitação do número de observações podem exigir uma abordagem diferente, como a “Random Forest”. O desempenho superior da floresta aleatória, pode ser atribuído à sua capacidade de lidar com interações não lineares entre variáveis aliada com sua capacidade de lidar com conjuntos de dados com ruídos e alta variância. Desse modo, a pesquisa evidencia a importância da escolha do modelo na previsão de fenômenos complexos, como o desmatamento, e destaca, portanto, a necessidade de estudos adicionais que considerem: outras possíveis variáveis externas que afetem o desmatamento; técnicas de pré-processamento mais avançadas para melhorar a precisão das previsões e outros tipos de modelos. Ademais, futuros trabalhos poderão explorar a integração de técnicas de machine learning, bem como o uso de dados complementares, para aprimorar a capacidade preditiva e a compreensão dos fatores que impulsionam o fenômeno do desmatamento.

Referências

- Klink, Carlos A.; Machado, Ricardo B. 2005. A conservação do Cerrado brasileiro. Megadiversidade Vol. 1.
- Aguiar, L.M.S.; Machado, Ricardo B.; Marinho-Filho, J. 2004. A diversidade biológica do Cerrado.
- Dias, B.F.S. 1992. Alternativas de desenvolvimento dos Cerrados: manejo e conservação dos recursos naturais renováveis. Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis (Ibama), Fundação Pró-Natureza (Funatura), Brasília, Brasil.
- Ministério do Meio Ambiente (MMA). 2016. Plano de Ação para a Prevenção e o Controle do Desmatamento no Cerrado. Brasil.
- Ministério do Meio Ambiente, ICMBio. Biodiversidade do Cerrado. Disponível em: <<https://www.icmbio.gov.br/cbc/conservacao-da-biodiversidade/biodiversidade.html>>. Acesso em: 4 abr. 2024.
- Ferneda, E. 2006. Redes neurais e sua aplicação em sistemas de recuperação de informação. Brasília, Brasil.
- Braga, A. P.; Carvalho, A. C. P. L. F.; Ludemir, T. B. 2000. Redes neurais artificiais: teoria e aplicações. Rio de Janeiro, Rio de Janeiro, Brasil.
- Crepaldi, P. G.; Avila, R. N. P.; Oliveira, J. P. M.; Rodrigues, P. R.; Martins, R. L. 2012. Um estudo sobre a árvore de decisão e sua importância na habilidade de aprendizado. Londrina, Paraná, Brasil.
- Garcia, S. C. 2003. O Uso de Árvores de Decisão na Descoberta de Conhecimento na Área da Saúde. UFRGS. Porto Alegre, Rio Grande do Sul, Brasil.

Santana, L. M. 2017. Aplicação de redes neurais recorrentes no reconhecimento automático da fala em ambientes com ruídos. UFS. São Cristóvão, Sergipe, Brasil.